

Clasificador de Imágenes del Cielo

Ana Blasco, Irene Barba, Lucía Benages, Xueyao An, Roberto Arevalillo, Adriana Marí

2026-01-15

Contents

1	Introducción al Problema	2
1.1	Objetivo del Proyecto	2
1.2	Origen de los Datos, Distribución y Balance de Clases	2
2	Preprocesamiento de Imágenes	3
2.1	Preprocesado para Clasificación Temporal	3
2.2	Preprocesado para Clasificación Meteorológica	3
3	Preparación de Datos para Entrenamiento	5
4	Entrenamiento I: Clasificación Temporal	5
4.1	Clasificación Binaria: Día vs. Noche	5
4.1.1	Análisis de Características	5
4.1.2	Selección del Mejor Modelo Binario	8
4.2	Clasificación Multiclase: Añadiendo Crepúsculo	8
4.2.1	Nuevas Características para detectar la clase Crepúsculo	9
4.3	Modelo Final Temporal	10
5	Entrenamiento II: Clasificación Meteorológica	11
5.1	Propuesta y Análisis de Características	11
5.2	Aplicación de PCA y Selección de Modelo	13
6	Evaluación con Conjunto de Test	14
6.1	Resultados en Clasificación Temporal	15
6.1.1	Resultados en Clasificación Temporal Binaria	15
6.1.2	Resultados en Clasificación Temporal Multiclase	16
6.2	Resultados en Clasificación Meteorológica	17
6.3	Conclusiones y Líneas Futuras	17
	Bibliografía	18

1 Introducción al Problema

1.1 Objetivo del Proyecto

El presente trabajo se enmarca dentro del ámbito del análisis digital de señales, aplicando técnicas de procesamiento de imágenes para la resolución de un problema de clasificación automática. El objetivo principal del proyecto es desarrollar un sistema capaz de etiquetar imágenes basándose exclusivamente en la información visual del cielo.

Distinguimos dos problemas de clasificación:

1. Clasificación temporal: se pretende determinar el momento del día en el que fue tomada la imagen, distinguiendo entre 3 clases: día, noche y crepúsculo.
2. Clasificación meteorológica: esta tarea se centra en evaluar las condiciones atmosféricas, buscando diferenciar patrones asociados a cielos despejados frente a cielos cubiertos (nublados).

A diferencia de los enfoques modernos basados en aprendizaje profundo (*Deep Learning*), este proyecto se centra en la extracción de características manual, tratando de identificar, extraer y analizar variables específicas de la señal de imagen — como componentes de color, brillo o texturas — que permitan discriminar las clases de forma lógica e interpretable.

Para la etapa de clasificación, se emplearán técnicas de Aprendizaje Automático (*Machine Learning*), utilizando concretamente el algoritmo Random Forest. Este modelo se basa en el ensamblaje de múltiples árboles de decisión que operan en conjunto, agregando sus predicciones individuales para obtener un resultado más robusto y menos propenso al sobreajuste que un único árbol.

Todos los materiales utilizados en el proceso de desarrollo de este proyecto se encuentran en el repositorio público de Github https://github.com/amalo8/Proyecto_Senyaes.git.

1.2 Origen de los Datos, Distribución y Balance de Clases

Las imágenes utilizadas en este proyecto se han recopilado a partir de diversas fuentes, con el objetivo de construir un dataset representativo y equilibrado para ambos problemas de clasificación. En primer lugar, se recopiló un conjunto masivo de entrenamiento proveniente de fuentes públicas y, en segundo lugar, se generó un conjunto de test independiente compuesto exclusivamente por fotografías propias de los miembros del grupo.

En lo referente al conjunto de entrenamiento para la clasificación temporal, utilizamos el “Time of Day Dataset” disponible en Kaggle. Este repositorio nos proporcionó un total de 2.661 imágenes, distribuidas en 920 imágenes para la clase de día, 756 para la noche y 985 para el crepúsculo. Esta distribución ofrece una cantidad suficiente y equilibrada de muestras por categoría que permite un entrenamiento adecuado del modelo sin necesidad de aplicar técnicas adicionales de balanceo de clases.

Para la clasificación meteorológica de entrenamiento, fue necesario realizar una fusión de distintas fuentes debido a la escasez de imágenes de cielos despejados en los datasets públicos consultados. Partimos del dataset “Clouds Photos” de Kaggle, del cual obtuvimos las 826 imágenes que conforman la clase nublado y apenas 124 imágenes de cielo despejado. Realizamos una búsqueda exhaustiva de otros conjuntos de datos de cielos despejados tanto en Kaggle como en otros repositorios públicos, sin embargo, las imágenes que encontramos no mostraban realmente cielos despejados sino parcialmente nublados, por lo que consideramos que no eran adecuadas para nuestro propósito ya que podían inducir a errores en el entrenamiento del modelo. Tras varios intentos sin éxito, decidimos ampliar la cantidad de imágenes de cielo despejado recurriendo a la plataforma de imágenes de stock libre Unsplash. Mediante una búsqueda manual bajo el término “*clear blue sky*”, integramos 578 imágenes adicionales a la clase despejado. Finalmente, el conjunto de entrenamiento

meteorológico alcanzó un total de 1.528 imágenes, logrando un balance mucho más adecuado con 702 imágenes para la clase despejado y 826 para la clase nublado.

Por otro lado, para la fase de test, optamos por no reservar un porcentaje de los datasets de entrenamiento, sino generar un conjunto de datos totalmente nuevo a partir de las galerías de fotos de los miembros del grupo. Esta estrategia nos permite comprobar el comportamiento del modelo ante imágenes cotidianas y no vistas previamente, asegurando una evaluación más realista de su capacidad de generalización. Este conjunto de test fue diseñado para estar perfectamente balanceado: para el problema temporal se utilizaron 120 imágenes (40 de día, 40 de noche y 40 de crepúsculo), mientras que para el problema meteorológico se seleccionaron 100 imágenes (50 de despejado y 50 de nublado).

2 Preprocesamiento de Imágenes

En esta fase del proyecto, el objetivo principal fue adaptar las imágenes originales para que la extracción de características posterior fuera lo más fiable posible. Dada la naturaleza distinta de los dos problemas a resolver, se optó por aplicar una estrategia de preprocesado diferenciada ya que no todas las imágenes requieren el mismo tratamiento: mientras que en algunos casos el entorno aporta información relevante, en otros puede introducir ruido que confunda al clasificador.

2.1 Preprocesado para Clasificación Temporal

Para el problema de clasificación temporal, tomamos la decisión de no realizar recortes y trabajar con la imagen completa. Esto se debe a que la distinción entre el día y la noche no reside únicamente en el cielo, sino en el contexto global de la imagen el cual puede aportar información visual relevante que se perdería al aislar la región superior. Por ejemplo, en una imagen de crepúsculo, los tonos anaranjados característicos se concentran casi siempre en la línea del horizonte, por lo que al recortar solo la parte superior del cielo, se podría perder esa franja de color quedando un cielo azul genérico que podría confundirse con una imagen diurna. Otro ejemplo lo ilustra la distinción entre día y noche, donde un cielo oscuro podría deberse a una gran tormenta, pero si se observan focos de luz como farolas o ventanas encendidas en la parte inferior de la imagen, se puede llegar a concluir que es de noche.

No obstante, aunque se preservó la imagen completa, fue necesario asegurar la consistencia de las dimensiones entre los distintos conjuntos de datos. Al analizar el dataset de entrenamiento, observamos que este ya se encontraba preprocesado y estandarizado a una resolución uniforme de 224x224 píxeles. Por el contrario, las imágenes del conjunto de test (provenientes de galerías personales) presentaban resoluciones muy dispares, lo que podría introducir sesgos numéricos en la extracción de características debido a la variabilidad en la cantidad de píxeles y detalles presentes en cada imagen.

Por este motivo, el proceso de normalización de escala se aplicó exclusivamente a las imágenes del conjunto de test, con el objetivo de alinearlas con las dimensiones del entrenamiento. Se fijó el lado mayor de cada imagen a un máximo de 224 píxeles, utilizando un reescalado proporcional. A diferencia de un recorte forzado, esta técnica respeta la relación de aspecto original de la fotografía, ya sea vertical u horizontal, asegurando que ninguna dimensión exceda el límite establecido sin deformar el contenido visual ni alterar las formas de los objetos de la imagen.

2.2 Preprocesado para Clasificación Meteorológica

Por el contrario, para la clasificación meteorológica, el enfoque fue opuesto. El objetivo es evaluar las condiciones atmosféricas, por lo que cualquier elemento que no pertenezca al cielo como edificios, montañas o vegetación, constituye ruido visual que podría confundir al clasificador, extrayendo características de elementos de la imagen no relevantes. Por ejemplo, una fachada blanca podría confundirse con una nube. Por ello, desarrollamos un algoritmo de segmentación específico para aislar una Región de Interés (ROI) que contuviera exclusivamente información del cielo, descartando el resto de la fotografía.

El algoritmo no se limita a realizar un recorte estático, sino que busca la mejor zona de cielo siguiendo una lógica de cuatro pasos:

1. Restricción del espacio: El análisis se limita estrictamente al 40% superior de la imagen, garantizando la presencia de cielo y evitando la inclusión de horizontes o elementos terrestres.
2. Ventana deslizante: Se emplea una ventana cuadrada dinámica (aprox. $1/3$ del ancho de la imagen) que se ajusta a la altura disponible. Esta escanea tres posiciones horizontales (izquierda, centro, derecha) para localizar el área más despejada.
3. Criterio de selección: Se elige el recorte óptimo minimizando la desviación típica (mayor homogeneidad), sujeto a superar un umbral mínimo de luminosidad media para descartar zonas oscuras o siluetas.
4. Normalización: El recorte resultante se redimensiona a 224×224 píxeles, garantizando que todas las muestras de entrada tengan exactamente las mismas dimensiones, independientemente del tamaño original de la imagen. Con ello, se evita que las diferencias de resolución introduzcan sesgos numéricos en el cálculo de las características.

Gracias a este preprocesado, fue posible detectar y corregir inconsistencias significativas en los datasets originales. Se observó que un gran número de imágenes etiquetadas como “nublado” generaban, tras el proceso, recortes de cielo totalmente azul. Esto no se debió únicamente a la tendencia de nuestra función de recorte a priorizar zonas homogéneas, sino a que las imágenes originales presentaban una nubosidad muy escasa. Al aislar la región de interés, se hizo evidente que estas muestras carecían de la densidad de nubes necesaria para representar fielmente su clase, lo que habría introducido ruido y confusión en el modelo. En consecuencia, estas imágenes fueron identificadas y eliminadas del conjunto de entrenamiento. Concretamente, 154 imágenes fueron descartadas por este motivo, ya que visualmente serían etiquetadas sin duda como “despejado”. El conjunto de imágenes nubladas se redujo de 826 imágenes a 672.

A continuación, la Figura 1 ilustra ejemplos de estas muestras descartadas, donde se aprecia cómo imágenes teóricamente nubladas contenían áreas de cielo despejado predominantes.




Figure 1: Imagen original vs Recorte en imágenes nubladas realmente despejadas

En la Figura 2 se muestran ejemplos adicionales del funcionamiento del algoritmo de recorte, ilustrando casos exitosos tanto para la clase de despejado como para la de nublado.



Figure 2: Recortes Exitosos Despejado y Nublado

3 Preparación de Datos para Entrenamiento

Para la construcción de los modelos predictivos, se procedió a la partición de los conjuntos de datos de ambos problemas siguiendo una estrategia de partición simple (*Hold-Out*). El objetivo de esta división es evaluar la capacidad de aprendizaje del algoritmo y evitar el sobreajuste, asegurando que el modelo sea capaz de generalizar patrones en lugar de memorizar imágenes específicas.

Se estableció una división del 80% de las imágenes destinado al conjunto de entrenamiento (*training set*), utilizado para la construcción de los árboles de decisión y el aprendizaje de características, y se reservó el 20% restante para el conjunto de validación (*validation set*), cuya única función la monitorización del entrenamiento y el ajuste de hiperparámetros del modelo. Para garantizar la consistencia estadística entre ambos subconjuntos, se aplicó una técnica de muestreo estratificado, gracias a la función *createDataPartition* de la librería *caret*. Este método asegura que la distribución de clases original se preserve en ambas particiones: la proporción de clases se mantiene idéntica tanto en el entrenamiento como en la validación, evitando sesgos en la evaluación del rendimiento.

En términos cuantitativos, esta distribución supuso el empleo de 2.129 imágenes de entrenamiento y 532 de validación para el problema temporal, mientras que para el problema meteorológico se destinaron 1.099 imágenes al entrenamiento y 275 a la validación.

4 Entrenamiento I: Clasificación Temporal

La clasificación de imágenes requiere un proceso previo de extracción de características. En esta sección, nos centraremos en la determinación de estas características y en el entrenamiento y validación de nuestro algoritmo. Como hemos mencionado anteriormente, se han empleado un conjunto de imágenes extraídas de repositorios públicos que nos garantizan una gran variedad de imágenes en diferentes contextos geográficos.

4.1 Clasificación Binaria: Día vs. Noche

En primer lugar, abordaremos este problema como una clasificación binaria (día/noche) para tener una primera toma de contacto en la extracción de características y en el entrenamiento del modelo. En el siguiente apartado, añadiremos una nueva categoría (crepúsculo) para lograr un modelo más completo. El objetivo es construir un modelo de aprendizaje supervisado que permita diferenciar claramente entre las dos categorías y, posteriormente, tenga la capacidad de generalizar correctamente en la clasificación de las imágenes capturadas por nosotros.

El procedimiento que hemos seguido para construir el clasificador ha sido el siguiente: incorporar sucesivamente características al modelo (de una en una). Esta decisión se ha tomado para poder observar si al añadir una característica, mejora o no nuestro clasificador. Esto nos da un control completo, en el que podemos identificar claramente que características funcionan mejor para diferenciar entre imagen de día y de noche.

4.1.1 Análisis de Características

Las primeras tres características son las medianas de la intensidad de los canales RGB (función `extraer_rgb`). Cada imagen se descompone en estas tres capas y se determina para cada píxel un valor de intensidad en cada una de ellas. Estos valores oscilan entre 0 (ausencia de color) y 1 (intensidad máxima). A continuación, se realiza la mediana de cada canal para cada imagen, obteniendo tres valores representativos. Se ha escogido la mediana en lugar de la media debido a su robustez frente a outliers. Por ejemplo, en imágenes nocturnas podemos encontrarnos con puntos de luz artificial intensos, como farolas, que podrían afectar. La mediana nos permitiría seguir conociendo un valor representativo de la intensidad de la imagen.

Con estas características esperaríamos valores bajos en las medianas RGB para las imágenes nocturnas ya que la mayoría de los píxeles tenderán a tener intensidades bajas. Por el contrario, en las imágenes diurnas,

las medianas RGB deberían ser más altas debido a la mayor presencia de luz natural. Si representamos en un diagrama de cajas los valores de la mediana (Figura 3, izquierda) distinguiendo entre día y noche, se observa claramente esta diferencia. Además, la mediana del canal azul es ligeramente superior a la de los otros dos canales en ambas categorías, resultado esperado ya que el color predominante en el cielo es el azul. Por otro lado, podemos confirmar a partir de los histogramas (Figura 3, derecha), que los histogramas de noche muestran una acumulación de frecuencias en los niveles bajos de RGB, mientras que los de día son más simétricos, ajustándose aproximadamente a una distribución gaussiana.




Figure 3: Diagrama de cajas (izquierda) e histogramas (derecha) de medianas RGB

Las siguientes características que hemos añadido son las medianas de los canales HSV (función `extraer_hsv`). La función permite extraer las medianas de las tres componentes: *Hue* que define el tono (descomponiendo H en sus valores de seno y coseno ya que al ser un ángulo no es conveniente tratarlo igual que las variables S y V), *Saturation* define la viveza del color y *Value* es la cantidad de luz presente en el color. Previamente a este cálculo se ha de realizar una conversión de los vectores de cada píxel de RGB a HSV con la función `rgb_a_hsv`.

Es importante destacar que la mediana de V es la que más información nos puede aportar ya que representa la cantidad de luz que hay en la imagen. En imágenes diurnas tiende a ser un valor alto debido a la gran cantidad de luz natural, mientras que en imágenes nocturnas el valor es bajo. Con respecto a los canales H y S podemos no encontrar diferencias significativas. Podemos ver en la Figura 4 estas observaciones, donde los histogramas de `V_mediana` para día y noche están menos solapados entre sí.




Figure 4: Diagrama de cajas (izquierda) e histogramas (derecha) de medianas HSV

La séptima característica es la detección de bordes mediante el filtro Sobel (**extraer_sobel**) para detectar cambios bruscos en la intensidad lumínica (se utiliza el valor medio de la magnitud de los gradientes horizontal y vertical de la intensidad). En un principio podríamos encontrar un valor mayor para imágenes diurnas ya que se pueden encontrar edificios/vegetación que debido a la gran cantidad de luz que hay en estas imágenes, se puedan identificar como bordes.

La octava característica es la detección de fuentes de luz (**extraer_fuentes_luz**). Consiste en la cuantificación de puntos de alta luminosidad. Se ha utilizado la fórmula de la luminancia ($L = 0.299R + 0.587G + 0.114B$) y se ha definido un umbral de 0,9 para detectar píxeles con intensidad cercana a la del blanco.

La novena característica es la entropía (**extraer_entropia**). A partir de la función **entropy** podemos determinarla. Puede ser útil ya que para valores bajos de la entropía esperamos una imagen más uniforme o con poca variación de niveles de intensidad, que podríamos encontrar en imágenes de noche. En la Figura 5 podemos ver los histogramas de estas últimas tres características, donde para cada una de ellas encontramos un gran solapamiento entre clases.




Figure 5: Histogramas de las variables Sobel, fuentes de luz y entropía

La décima característica es el cálculo del porcentaje de píxeles oscuros, es decir, de baja luminosidad (**extraer_pixeles_oscuros**). Utilizando de nuevo la fórmula de la luminancia, L , determinamos el porcentaje de píxeles oscuros en cada imagen (en imágenes nocturnas esperamos un porcentaje mayor).

La undécima característica (**extraer_rango_dinamico_V**) mide el rango del canal V, es decir, calcula la diferencia entre el valor máximo de V y el valor mínimo de V de cada imagen. Un rango de 1 indica que la imagen tiene píxeles donde hay ausencia de luz (negro) hasta la máxima presencia de luz (blanco). Lo habitual es encontrar un rango más amplio en imágenes de día, aunque en las imágenes nocturnas pueden haber luces artificiales.

La duodécima característica (**extraer_blur_V**) consiste en calcular la media del canal V una vez aplicado un filtro de paso bajo gaussiano (blur) para suavizar la imagen y eliminar variaciones bruscas o ruido de alta frecuencia. Esto podría ayudar a separar mejor un día nublado (gris) de una noche iluminada. Para estas últimas tres características representamos de nuevo los histogramas mostrados en la Figura 6, donde observamos que el que más destaca es el tercero ya que se observa una gran diferencia entre clases. No obstante, finalmente no añadiremos esta característica ya que está altamente correlacionada con la variable **V_mediana** (0.97).




Figure 6: Histogramas de las variables píxeles oscuros, rango de V y media de V con filtro blur

La última característica es el cálculo de la desviación estándar de las intensidades del canal V (`extraer_sd_V`). Nos permite determinar la dispersión del brillo de una imagen con respecto a su media. De día esperamos una desviación mayor debido a la gran variedad de objetos que nos podemos encontrar en las imágenes como sombras, edificios, árboles, etc. Podemos verlo gráficamente a través del diagrama de cajas mostrado en la Figura 7. Respecto al histograma sí que observamos que no hay una gran diferencia entre día y noche aunque en este caso `sd_V` y `V_mediana` están muy poco correlacionadas (0.13).




Figure 7: Diagrama de cajas (izquierda) e histogramas (derecha) de la desviación estándar de V

4.1.2 Selección del Mejor Modelo Binario

Como hemos mencionado anteriormente, estas características se han ido añadiendo sucesivamente al modelo. Finalmente las características utilizadas en este modelo han sido 8: `R_mediana`, `G_mediana`, `B_mediana`, `H_cos_mediana`, `H_sin_mediana`, `S_mediana`, `V_mediana` y `sd_V`; alcanzando un accuracy del 90.15% para el conjunto de validación. Por otro lado, al analizar la importancia de las características mediante el índice *MeanDecreaseGini*, se observa que las más influyentes a la hora de clasificar han sido `G_mediana` con un valor de 221.17, seguido de `V_mediana` con 117.04 y `B_mediana` con 98.48.

4.2 Clasificación Multiclase: Añadiendo Crepúsculo

Una vez validado el enfoque para la clasificación binaria Día/Noche, el problema se amplía a una clasificación multiclase incorporando una tercera categoría: Crepúsculo. Esta clase representa un estado intermedio entre el día y la noche, caracterizado por una iluminación reducida, la presencia de tonos cálidos y una marcada estructura vertical del brillo en la imagen.

Desde el punto de vista visual, el crepúsculo combina elementos propios de ambas clases: zonas del cielo todavía iluminadas junto con regiones oscuras o con iluminación artificial. En nuestro conjunto de datos es habitual observar un suelo ya oscuro mientras que el cielo sigue recibiendo luz residual del sol bajo en el

horizonte, lo que genera un gradiente vertical de luminosidad muy marcado. Esta combinación convierte al crepúsculo en una clase especialmente compleja y exige la incorporación de características que capturen simultáneamente el color y la estructura espacial de la imagen.

4.2.1 Nuevas Características para detectar la clase Crepúsculo

Para abordar la complejidad de la clase Crepúsculo, se siguió una estrategia incremental similar a la utilizada en la clasificación binaria: se parte de un modelo base y se van incorporando progresivamente nuevas características diseñadas específicamente para capturar los patrones visuales propios de esta franja horaria.

4.2.1.1 Modelo base: Color y luminosidad global (RGB + HSV + sd(V))

El primer modelo multiclase se construyó utilizando las mejores variables obtenidas en la clasificación binaria: **R_mediana**, **G_mediana**, **B_mediana**, **H_cos_mediana**, **H_sin_mediana**, **S_mediana**, **V_mediana** y **sd_V**. Realizando un entrenamiento con estas variables pero con los datos de las tres clases, este modelo alcanza un accuracy del 76.7% en validación. En general, el modelo presentaba una buena separación entre Día y Noche, pero una mayor confusión con la clase Crepúsculo, lo que refleja su naturaleza intermedia. Las variables más importantes según el índice MeanDecreaseGini son **G_mediana** y **V_mediana**, confirmando que la luminosidad y el color dominante del cielo son los factores principales para diferenciar los distintos momentos del día.

4.2.1.2 Agregación de la proporción de tonos cálidos

A continuación, se incorporó la variable **Porcentaje_Calidos**, diseñada para cuantificar la presencia de píxeles con tonos rojizos y anaranjados típicos del amanecer y el atardecer. Con esta característica, el modelo mejora ligeramente su rendimiento hasta un accuracy del 76.9%. La sensibilidad para la clase Crepúsculo aumenta, lo que indica que el modelo identifica mejor imágenes con colores cálidos característicos de esta franja horaria. Además, **Porcentaje_Calidos** aparece entre las variables con mayor importancia, lo que confirma su relevancia para detectar crepúsculos.




Figure 8: Diagrama de cajas de la proporción de tonos cálidos

4.2.1.3 Incorporación de gradientes por bandas horizontales

Como primer intento para capturar la estructura vertical del crepúsculo, se introdujo la variable `Gradiente_V_Bandas`, que mide la variación de luminosidad del canal V dividiendo la imagen en bandas horizontales. Esta característica pretende modelar el patrón típico del crepúsculo, donde el cielo es más brillante que el suelo.

La inclusión de esta variable mejora el rendimiento del modelo hasta un accuracy del 80.6%, lo que confirma que la estructura vertical del brillo aporta información relevante para identificar el crepúsculo. No obstante, aunque se observa una mejora respecto al modelo base, el patrón capturado por bandas horizontales resulta todavía demasiado rígido para describir adecuadamente escenas reales, donde la transición entre cielo y suelo no siempre es perfectamente horizontal.

4.2.1.4 Incorporación de características por bloques espaciales

Para superar las limitaciones del enfoque por bandas, se optó por una representación más flexible basada en bloques espaciales. En este enfoque, la imagen se divide en regiones (superior, central e inferior) y se extraen estadísticas de color y luminosidad en cada bloque, lo que permite capturar la estructura espacial sin imponer una geometría estrictamente horizontal. Este modelo alcanza un accuracy del 80.1%, un rendimiento similar al obtenido con bandas, pero con una interpretación más rica: las variables más importantes corresponden a los bloques superiores y centrales, que contienen principalmente el cielo y el horizonte. Esto indica que el modelo está utilizando activamente la distribución espacial del color y la luminosidad para distinguir entre día, noche y crepúsculo. Por este motivo, el enfoque basado en bloques se selecciona como la representación espacial preferida para los siguientes experimentos, ya que ofrece una descripción más realista de las escenas que el uso de bandas horizontales.

4.2.1.5 Incorporación de la proporción de píxeles extremos por bloque

Finalmente, se añadieron variables que cuantifican la proporción de píxeles muy oscuros y muy brillantes en cada bloque, lo que permite capturar de forma explícita el fuerte contraste típico del crepúsculo entre cielo y suelo. Este modelo final alcanza el mejor rendimiento, con un accuracy del 81.2%. La sensibilidad de la clase Crepúsculo supera el 84%, lo que indica una mejora sustancial en su detección. Las variables más importantes incluyen `G_mediana`, `V_mediana`, así como varias proporciones de píxeles extremos por bloques, confirmando que la combinación de color, luminosidad y estructura espacial es clave para identificar correctamente esta clase.

En conclusión, la inclusión progresiva de características diseñadas específicamente para capturar los colores cálidos, la estructura vertical del brillo y los contrastes espaciales permite mejorar de forma sistemática la detección del crepúsculo, pasando de un modelo base razonable (76.7%) a un modelo final notablemente más preciso (81.2%).

4.3 Modelo Final Temporal

Tras evaluar de forma sistemática los distintos conjuntos de características propuestos para la clasificación temporal multiclase, se seleccionó como solución principal el modelo que combina información de color, luminosidad y estructura espacial mediante: las medianas RGB y HSV, la desviación estándar del canal V, la proporción de tonos cálidos, las características espaciales por bloques y la proporción de píxeles extremos (muy oscuros y muy brillantes) en cada bloque.

Este conjunto de variables permite capturar simultáneamente la cantidad de luz, la tonalidad del cielo y la distribución espacial del brillo, que son los elementos físicos clave para distinguir entre Día, Noche y Crepúsculo. El modelo Random Forest entrenado con estas características alcanza una precisión global del 81.2% en el conjunto de validación, lo que indica una concordancia elevada entre las predicciones y las etiquetas reales. La sensibilidad de la clase Crepúsculo supera el 84%, mostrando que el modelo es capaz de identificar de forma fiable las situaciones de transición entre día y noche. El análisis de importancia de

variables confirma que las características más influyentes están relacionadas con la luminosidad y el color ($G_mediana$, $V_mediana$) y con la estructura espacial del brillo, en particular las proporciones de píxeles extremos y las estadísticas por bloques. Esto refuerza la interpretación física del modelo: el crepúsculo no se caracteriza únicamente por un nivel intermedio de luz, sino por una combinación específica de contrastes verticales y tonos cálidos.

5 Entrenamiento II: Clasificación Meteorológica

En esta segunda parte del proyecto nos detendremos en el problema de clasificación de imágenes de cielo entre aquellos que están nublados y aquellos que están despejados.

5.1 Propuesta y Análisis de Características

Para entrenar este nuevo clasificador hemos propuesto un total de 31 características: los valores de los tres canales RGB originales de la imagen, los valores de HSV; descomponiendo H en sus valores de seno y coseno, el brillo, el contraste, la magnitud media del operador de Sobel (para detectar los bordes de las nubes con mayor precisión hemos aplicado un filtro de paso alto a las imágenes antes de extraer esta característica), los ratios de píxeles azules, blancos, grises, el ratio de sombras, la desviación estándar de V y los valores medios de S por bloques. A continuación analizaremos cada una de estas características.

Empecemos por los valores medianos del espacio RGB: al representar sus histogramas (izquierda, Figura 9), vemos que en los 3 casos podríamos considerar que los datos siguen una distribución normal. Si bien es llamativa la alta concentración del valor 0 en el canal R , esto podría deberse simplemente a la ausencia de este color en imágenes del cielo despejado y nublado. También es destacable que, como era de esperar, el canal con valores medianos más altos es el B y también es este canal el que presenta una diferencia entre la distribución de los datos según las clases más apreciable. Una vez comprobada la distribución que siguen nuestros datos, al realizar un diagrama de cajas (derecha, Figura 9) podemos observar que, efectivamente, el canal B es el que proporciona una distinción mayor entre clases, aunque esta diste de ser completa.




Figure 9: Histogramas y diagramas de caja de los canales RGB

Al representar los histogramas de los 4 valores extraídos de la representación de las imágenes en el espacio HSV (izquierda, Figura 10), podemos observar que todas, excepto $\cos H$ parecen presentar una distribución normal. En el diagrama de cajas (derecha, Figura 10) podemos observar que la mayor distancia entre clases la presenta el canal S .

Como podemos ver en los histogramas de la Figura 11, la variable **Brillo** presenta una marcada distribución normal, mientras que las demás variables distan mucho de hacerlo, sobre todo **Ratio_Azul**. El histograma de la variable **Brillo** nos muestra que no es capaz de distinguir claramente entre clases, ya que las medianas de ambas poblaciones están muy próximas, lo que denota que el brillo entre imágenes de cielos despejados




Figure 10: Histogramas y diagramas de caja de los canales HSV

y cielos nublados es bastante similar. De forma contraria, y aunque no siga una distribución gaussiana, podemos ver en los histogramas de los porcentajes de píxeles azules y grises una diferenciación entre cielos despejados y nublados clara, teniendo la mayoría de imágenes de cielos despejados ratios muy altos (cerca de 1 en **Ratio_Azul**), mientras que la mayoría de cielos nublados tiene ratios muy bajos (cerca de 0 en **Ratio_Azul**). Contrariamente a lo que cabría esperar, los histogramas de los ratios de sombras y blancos se superponen, lo cual podría indicar que todas las imágenes, independientemente de su clase, presentan rangos de saturación y valor muy similares, cosa poco intuitiva porque la variable de HSV que mejor distinguía las clases era la saturación (S).




Figure 11: Histogramas de brillo, contraste y Sobel, diagrama de caja de brillo

Por esto último, para cada imagen, hemos calculado el valor medio de la saturación en cada bloque. Dichos bloques son el resultado de dividir la imagen en 16 rectángulos idénticos. Hemos decidido incorporar dichas variables porque, aunque en los histogramas los valores que aporta cada una sean similares (Figura 12), la combinación única de valores medianos en los distintos bloques de cada imagen puede ayudar a describir los cambios de grises y la textura de las nubes de forma cuantitativa.



Figure 12: Histogramas de la saturación (S) media por bloque

5.2 Aplicación de PCA y Selección de Modelo

Después de proponer las variables descritas en el apartado anterior para la diferenciación entre cielos nublados y despejados, nos dimos cuenta de que, aunque algunas variables estarían fuertemente correlacionadas de forma natural (como los valores de **Brillo** y **V_mediana**, o todas las variables que miden la saturación cada una en su bloque), al representar las correlaciones entre todas las variables (izquierda, Figura 13) pudimos observar que había muchas más variables altamente correlacionadas de las que pudiesemos haber esperado en un principio (como las variables **G_mediana** y **Brillo**, o las variables **R_mediana** y **S_mediana**).

Es por esto que, para no proporcionar información redundante, e intentar describir la máxima información posible que proporcionan nuestras variables minimizando el número de las mismas a la hora de entrenar el

modelo, decidimos aplicar un Análisis de Componentes Principales (Amat Rodrigo (2017); Prasar (2017)) a nuestras variables. Al realizar este análisis y representar gráficamente tanto la proporción de varianza explicada por cada componente principal (Figura 14), como la proporción de varianza acumulada de las mismas, vimos que, a partir de la decimoquinta componente principal, la proporción de varianza que explica cada una de las siguientes componentes es casi imperceptible. Consecuentemente escogimos solamente las 15 primeras componentes principales para entrenar nuestro modelo de Random Forest y tratar de evitar sobreajustarnos a los datos de entrenamiento.




Figure 13: Mapa de correlaciones entre las variables para la clasificación meteorológica




Figure 14: Proporciones y proporciones acumuladas de varianza explicada por el PCA

Después de entrenar nuestro modelo con las 15 primeras componentes resultado de la PCA, en la etapa de validación el modelo ha alcanzado un accuracy del 95,62%. Además, al analizar la importancia de las características mediante el índice *MeanDecreaseGini*, se observa que las componentes principales influyen más significativamente en orden descendente (es decir, primero PC1, después PC2, y así sucesivamente), por su propia naturaleza.

6 Evaluación con Conjunto de Test

Tras haber desarrollado los modelos Random Forest pertinentes para la clasificación temporal y meteorológica de imágenes, procederemos a evaluar su desempeño en un conjunto de test, constituido por imágenes tomadas por los integrantes del grupo y preprocesadas como se indicó en el apartado 2.

Para ello crearemos un modelo definitivo Random Forest para cada problema de clasificación estudiado

que utilice las características óptimas escogidas para cada caso y se entrene usando todo el conjunto de train disponible, es decir, se incorporará al entrenamiento de los modelos desarrollados el conjunto de datos utilizado previamente para validación.

6.1 Resultados en Clasificación Temporal

Para la clasificación temporal contamos con dos modelos diferentes desarrollados, un Random Forest más sencillo y con un menor número de características para la clasificación binaria de imágenes en día/noche y otro más complejo para la clasificación de imágenes en día/noche/crepúsculo.

6.1.1 Resultados en Clasificación Temporal Binaria

Evaluaremos el modelo seleccionado en el apartado 4.1.2 en un total de 80 imágenes de test, de las cuales 40 pertenecen a la clase Día y 40 pertenecen a la clase Noche. Realizando las predicciones y comparando con las etiquetas reales obtenemos las siguientes métricas de evaluación:

Table 1: Estadísticos de la matriz de confusión para el test de nuestro clasificador temporal binario.

Exactitud	Sensibilidad	Especificidad	Precisión	F1
0.988	0.975	1	1	0.987

Encontramos que el modelo seleccionado para la clasificación binaria es robusto y clasifica bien nuestras imágenes de test ya que posee una exactitud balanceada de 98.8%. A partir de los resultados obtenidos averiguamos que solamente se ha clasificado incorrectamente una imagen. Para analizar más detalladamente este error representaremos esta imagen y sus características en relación al resto de imágenes de test en la Figura 15




Figure 15: Imagen mal clasificada para el modelo binario Día/Noche

Podemos comprobar que la mayoría de las características de la imagen mal clasificada se encuentran en un rango intermedio entre las características de las imágenes bien clasificadas de día y noche, teniendo valores de `V_mediana`, `R_mediana` y `G_mediana` altos para ser una imagen de noche. Esto es debido a que, aunque sea una imagen nocturna, está muy iluminada y presenta colores vivos, hecho que puede confundir al clasificador.

6.1.2 Resultados en Clasificación Temporal Multiclase

Evaluaremos el modelo seleccionado en el apartado 4.3 en un total de 120 imágenes de test, equitativamente distribuidas en las clases Día, Noche y Crepúsculo. Realizando las predicciones y comparando con las etiquetas reales obtenemos las siguientes métricas de evaluación:

Table 2: Estadísticos de la matriz de confusión para el test de nuestro clasificador temporal multiclase.

Clase	Exactitud	Sensibilidad	Especificidad	Precisión	F1
Noche	0.925	0.875	0.975	0.946	0.909
Día	0.931	0.925	0.938	0.881	0.902
Crepúsculo	0.881	0.850	0.912	0.829	0.840

Obtenemos también la exactitud conjunta (todas las predicciones correctas respecto del total) para las tres clases que será de 88.3%. Encontramos que se ha reducido la exactitud respecto del caso de clasificación binaria, lo cual es esperable ya que este es un problema más complejo. No obstante las características adicionales para este clasificador han permitido mantener un buen desempeño en nuestras imágenes de test. A partir de nuestros resultados podemos comprobar que la nueva clase, Crepúsculo, es la que ha dado lugar a mayor confusión en el modelo: del las 14 imágenes mal clasificadas 13 de los errores vienen dados por imágenes de la categoría Crepúsculo siendo clasificadas como Día/Noche o imágenes de las categorías Día/Noche siendo clasificadas como Crepúsculo. La tendencia a confundir la categoría Crepúsculo queda también reflejada en sus correspondientes estadísticos de la matriz de confusión, que son menores con respecto a los de las otras clases.

Dado que temporalmente el crepúsculo es el momento que se encuentra entre el día y la noche es razonable que estas imágenes presenten una mayor similitud a Día o Noche, dando lugar a un mayor error de clasificación para esta clase.




Figure 16: Imágenes mal clasificadas para el modelo multiclase Día/Noche/Crepúsculo

Realizando una inspección visual de las imágenes mal clasificadas, como se ejemplifica en la Figura 16, encontramos que las imágenes de Noche mal clasificadas como Crepúsculo presentan buena iluminación (para tratarse de una imagen nocturna), fuentes de luz claras y cierta presencia de tonos rojizos, similarmente las única imagen de Noche mal clasificada como Día presenta también buena iluminación y tonos muy vivos. En cuanto a Crepúsculo la mayoría de las imágenes mal clasificadas como Día presentan una importante proporción de tonos azules en el cielo, mientras que la única imagen predicha como Noche presenta tonos muy oscuros en gran parte de la imagen. Finalmente, para la categoría Día no se encuentra ninguna imagen erróneamente etiquetada como Noche, pero sí algunas para las que se ha predicho la categoría Crepúsculo, en nuestro conjunto de test las imágenes para las que se ha encontrado este error presentan una parte sombreada en la parte inferior y horizontes claramente definidos, que quizá puede resultar similar al paisaje característico de una imagen durante el crepúsculo.

6.2 Resultados en Clasificación Meteorológica

Hemos evaluado el modelo del apartado 5.2 sobre un total de 100 imágenes de test, siendo 50 de la clase nublado y 50 de la clase Despejado. Realizando las predicciones y comparando con las etiquetas reales obtenemos las siguientes métricas de evaluación:

Table 3: Estadísticos de la matriz de confusión para el test del clasificador meteorológico binario.

Exactitud	Sensibilidad	Especificidad	Precisión	F1
0.810	0.640	0.980	0.969	0.771

El modelo seleccionado para la distinción entre cielos nublados y despejados clasifica nuestras imágenes de test con una exactitud balanceada del 81%. Fijándonos en la matriz de confusión comprobamos que solo clasifica erróneamente una imagen del cielo despejado, mientras que clasifica 18 imágenes de cielos nublados incorrectamente. La mayoría de las imágenes de cielos nublados mal clasificadas o bien son recortes muy homogéneos, o bien son trozos de cielo azul (recorte no adecuado), habiendo solo una imagen de nubes bien definidas que haya sido mal clasificada. Por otra parte la única imagen de cielo despejado mal clasificada presenta un cielo grisáceo y un tercio de la imagen es una arboleda, cuya presencia puede haber confundido al clasificador. Dicha imagen y otras tres mal clasificadas de la clase Nublado pueden encontrarse en la Figura 17.



Figure 17: Imágenes mal clasificadas para el modelo meteorológico

6.3 Conclusiones y Líneas Futuras

Table 4: Resumen de características y métricas de rendimiento de los modelos finales

Clasificador	Variables	Exactitud.Validación	Exactitud.Test
Temporal binario	Mediana RGB y HSV (R, G, B, H_cos, H_sin, S, V); desviación estándar de V.	90.15 %	98.80 %
Temporal multiclase	Mediana RGB/HSV + sd(V) + % Tonos Cálidos + % Píxeles Extremos + Estadísticas por bloques espaciales (3x1).	81.20 %	88.30 %
Meteorológico	Mediana RGB/HSV + Ratios (Azul/Blancos/Grises) + Brillo/Contraste + Sobel + Saturación por bloques → PCA (15 componentes).	95.62 %	81.00 %

El desarrollo de este proyecto ha permitido demostrar que la extracción manual de características, combinada con algoritmos de aprendizaje clásico como Random Forest, es una estrategia viable y efectiva para la clasificación de imágenes del cielo, ofreciendo una alternativa interpretable a los modelos de caja negra del aprendizaje profundo.

En cuanto a la clasificación temporal, se ha demostrado que la distinción binaria entre día y noche es un problema robusto, resoluble casi exclusivamente mediante el análisis de histogramas de color y luminosidad. Sin embargo, la inclusión de la clase Crepúsculo reveló la necesidad de incorporar información espacial. La segmentación por bloques y el análisis de gradientes verticales resultaron determinantes para capturar la transición de luz característica de esta franja horaria, logrando una exactitud del 88.3% en un conjunto de test independiente, lo que valida la capacidad de generalización del modelo ante imágenes no vistas.

Por otro lado, la clasificación meteorológica presentó desafíos únicos relacionados con el ruido visual (edificios, vegetación). La implementación de un algoritmo de recorte inteligente fue la clave del éxito en esta etapa, permitiendo limpiar el dataset de entrenamiento y eliminar falsos nublados. Además, el análisis de correlaciones evidenció una alta redundancia entre las variables cromáticas y de textura, lo cual justificó el uso del Análisis de Componentes Principales (PCA). Seleccionando las 15 primeras componentes, se logró reducir la dimensionalidad y evitar el sobreajuste, alcanzando un 81% de exactitud en el test final con imágenes reales propias.

Finalmente, como líneas futuras de investigación, se plantea ampliar el problema meteorológico añadiendo clases más complejas como lluvia, nieve o niebla, lo cual requeriría la exploración de nuevas características de textura. Asimismo, sería conveniente mejorar el algoritmo de segmentación de cielo mediante técnicas de detección de bordes más avanzadas para capturar contornos irregulares con mayor precisión. Por último, resultaría de gran interés comparar el rendimiento de estos modelos frente a arquitecturas de aprendizaje profundo (CNN), que, aunque suelen ofrecer una capacidad predictiva superior, su naturaleza sacrifica la interpretabilidad directa de las propiedades visuales (como el color o el contraste) que sí permite analizar nuestro enfoque de extracción manual.

Bibliografía

- Amat Rodrigo, J. (2017). *Análisis de componentes principales (principal component analysis, PCA) y t-SNE*. https://cienciadedatos.net/documentos/35_principal_component_analysis
- Cheng, H.-Y., & Lin, C.-L. (2017). Cloud detection in all-sky images via multi-scale neighborhood features and multiple supervised learning techniques. In *Atmospheric Measurement Techniques* (1; Vol. 10, pp. 199–208). Copernicus GmbH. <https://amt.copernicus.org/articles/10/199/2017/amt-10-199-2017.pdf>
- Dev, S., Lee, Y. H., & Winkler, S. (2014). *Systematic study of color spaces and components for the segmentation of sky/cloud images* (pp. 5102–5106). <https://ieeexplore.ieee.org/document/7026033>
- Essa, O. (2025). *Clouds photos*. <https://www.kaggle.com/datasets/jockeroika/clouds-photos>
- Heinle, A., Macke, A., & Srivastav, A. (2010). Automatic cloud classification of whole sky images. In *Atmospheric Measurement Techniques* (3; Vol. 3, pp. 557–567). <https://amt.copernicus.org/articles/3/557/2010/>
- Khouja, A. (2023). *Time of day dataset*. <https://www.kaggle.com/datasets/aymenkhouja/timeofdaydataset>
- Prasar, A. (2017). *Weight lifting exercise analysis*. <https://www.rpubs.com/aprasar/293450>
- Taha, M., Zayed, H. H., Nazmy, T., & Khalifa, M. (2016). Day/night detector for vehicle tracking in traffic monitoring systems. In *International Journal of Computer, Electrical, Automation, Control and Information Engineering* (1; Vol. 10, p. 101). https://www.researchgate.net/profile/Mohamed-Taha-29/publication/324759015_Daynight_detector_for_vehicle_tracking_in_traffic_monitoring_systems/links/5b828f194585151fd133c5fe/Day-night-detector-for-vehicle-tracking-in-traffic-monitoring-systems.pdf